

DISPARIDADE DE GÊNERO

Projeto em Ciência de Dados I

- Augusto Henrique Gonçalves Valbonetti
- Eduardo Fraga Fonseca Gomes
- Gustavo Bacellar Nunes Soares
- Leonardo Andrade Caetano Dornelas
- Pedro Lansdowne Oliveira
- Vitor Martins Gonçalves

Hipóteses



O projeto foi dividido em 6 hipóteses, uma para cada integrante

- Gustavo: Identificar como a contratação no setor de dados é impactada pelo gênero
- Pedro: Identificar como a satisfação de uma pessoa no setor de dados é impactada pelo gênero
- Eduardo: Identificar como o nível de ensino no setor de dados é impactado pelo gênero
- Augusto: Prever como a possibilidade de mudança de emprego no setor de dados em um período de 6 meses é impactada pelo gênero
- Leonardo: Identificar como a situação atual de trabalho no setor de dados é impactada pelo gênero e região
- Vitor: Identificar como a progressão de carreira no setor de dados é impactada pelo gênero

Pergunta Orientada a Dados


Identificar como a situação atual de trabalho
no setor de dados é impactada pelo gênero e
a região

Objetivo



Desenvolver um sistema inteligente para identificar pessoas em situação de desemprego, priorizando a sensibilidade (recall) da classe Desempregado(a). Em cenários sociais e políticos, como o mapeamento da vulnerabilidade no mercado de trabalho, é mais crítico deixar de identificar alguém desempregado do que cometer um falso positivo. Por isso, o foco foi maximizar a capacidade do modelo de não deixar desempregados passarem despercebidos.

DICIONÁRIOS DE DADOS



STATE OF DATA 2023

● Contexto da base

pesquisa anual, do maior panorama do mercado de trabalho em dados no Brasil

● Amostragem de dados

Segue a direita uma pequena amostra do dicionário de dados

Atributo	Significado	Tipo
Idade	Idade do respondente.	Inteiro
Genero	Gênero do respondente.	Categórico
Cor/raca/etnia	Cor/raça/etnia do respondente.	Categórico
PCD	Indica se o respondente é Pessoa com Deficiência.	Categórico
UF	Unidade Federativa onde o respondente mora.	Categórico
Regiao onde mora	Região do Brasil onde o respondente mora	Categórico
Nível de Ensino	Nível de ensino do respondente	Categórico
Área de formação	Área de formação acadêmica do respondente.	Categórico
Situação de trabalho	Situação atual de trabalho do respondente	Categórico

RAIS 2023

BASE AUXILIAR

● Contexto da base

Pesquisa anual, contém dados de estoque e remuneração de cada região do Brasil.

● Amostragem de dados

Segue a direita uma pequena amostra do dicionário de dados

Atributo	Significado	Tipo
Região	Região	Categórico
2023	ESTOQUE DE EMPREGOS FORMAIS da região em 2024	Numérico
2024	ESTOQUE DE EMPREGOS FORMAIS da região em 2023	Numérico
Variação Absoluta	Variação Absoluta de estoque de emprego na região 2023 para 2024	Numérico
Variação Relativa	Variação Relativa de estoque de emprego na região 2023 para 2024	Numérico

Análise da Coluna 'Idade'

- Média: 31.96 anos.
- Mediana: 30.00 anos.
- Moda: 27.00 anos (o valor mais frequente de idade).
- Desvio Padrão: 7.55 anos (indica a dispersão das idades em torno da média).
- Mínimo: 18.00 anos.
- Máximo: 73.00 anos.
- Quartis: 25% dos respondentes têm 27 anos ou menos, 50% têm 30 anos ou menos, e 75% têm 36 anos ou menos.

Análise da Coluna 'Genero'

- Média: 0.25 (considerando a codificação, indica a proporção relativa entre os gêneros).
- Mediana: 0.00.
- Moda: 1.00 (o gênero com maior frequência na codificação).
- Desvio Padrão: 0.43.
- Mínimo: 0.00.
- Máximo: 1.00.
- Quartis: 75% dos valores codificados de gênero são 0.

Análise da Coluna 'Situação de trabalho'

- Média: 0.09 (indica a proporção de respondentes em uma das categorias de situação de trabalho na codificação).
- Mediana: 0.00.
- Moda: 1.00 (a situação de trabalho com maior frequência na codificação).
- Desvio Padrão: 0.28.
- Mínimo: 0.00.
- Máximo: 1.00.
- Quartis: 75% dos valores codificados para situação de trabalho são 0.


Análise da Coluna 'Nível de Ensino'

- Média: 2.59 (valor médio da codificação do nível de ensino).
- Mediana: 3.00.
- Moda: 3.00 (o nível de ensino com maior frequência na codificação).
- Desvio Padrão: 1.00.
- Mínimo: 1.00.
- Máximo: 5.00.
- Quartis: 75% dos respondentes têm nível de ensino codificado como 3 ou menos.





DESCRIÇÃO DOS DADOS


- Média: Medida de tendência central.
- Mediana: Valor central dos dados ordenados.
- Moda: Valor mais frequente nos dados.
- Desvio Padrão: Medida de dispersão dos dados em torno da média.
- Variância: Quadrado do desvio padrão, outra medida de dispersão.
- Mínimo e Máximo: Limites inferior e superior dos dados.
- Quartis: Valores que dividem os dados em quatro partes iguais (25%, 50% - mediana, 75%).




GRÁFICOS DA ANÁLISE EXPLORATÓRIA




Distribuição de Idade




Distribuição da Situação de Trabalho



Distribuição por Gênero



Distribuição por Área de formação em tecnologia



A Transformação dos Dados

Objetivo: Transformar um dataset complexo e "sujo" em uma base de dados estruturada, limpa e 100% numérica, pronta para ser usada pelos modelos de Machine Learning.

Abordagem: Seguimos um fluxo de 3 etapas principais:

- Seleção
- Limpeza e Padronização
- Codificação para Modelagem





Seleção de atributos

Seleção de Colunas:

Iniciamos com um grande número de colunas e selecionamos apenas as 8 que eram essenciais para a nossa hipótese.

Atributos escolhidos:

Idade;
Gênero;
Cor/raca/etnia;
PCD;
Região onde mora;
Nível de Ensino;
Área de formação em tecnologia
Situação de trabalho.



Tratamentos dos valores faltantes ou omissos

```
print("\nContagem de nulos por coluna (após limpeza):")  
print(df.isnull().sum())
```



```
Contagem de nulos por coluna (após limpeza):  
Idade                                0  
Genero                               0  
Cor/raca/etnia                       0  
PCD                                   0  
Região onde mora                     0  
Área de formação em tecnologia       0  
Situação de trabalho                 0  
Nível de Ensino                      0  
dtype: int64
```



Limpeza de dados concluída.
Formato do DataFrame após limpeza: (5008, 8)

✓ 3. LIMPEZA E PRÉ-PROCESSAMENTO

```
[ ] # Remover linhas com valores nulos em colunas essenciais  
df.dropna(subset=['Região onde mora', 'Área de formação em tecnologia', 'Idade', 'Nível de Ensino', 'Situação de trabalho'], inplace=True)  
  
# Remover valores indesejados nas colunas 'Genero' e 'PCD'  
df = df[~df['Genero'].isin(['Outro', 'Prefiro não informar'])].copy()  
df = df[~df['PCD'].isin(['Prefiro não informar'])].copy()
```


Tratamento dos Valores Inconsistentes

O teste Qui-Quadrado (chi2) foi utilizado como uma técnica de seleção de features para medir a importância dos atributos. O objetivo principal foi avaliar a relação estatística entre cada variável categórica e a variável alvo, Situação de trabalho.

Chi2-Score:

Quando maior o valor

=

Maior a importância desse atributo

P_Value:

Quanto menor o valor

=

Maior a importância desse atributo

```
--- Teste Qui-Quadrado com o Alvo Categórico ---
      Feature  Chi2_Score  P_Value
3      Nível de Ensino  36.661369  1.405370e-09
12     Região onde mora_Nordeste  27.193929  1.840356e-07
0      Genero  17.001674  3.734688e-05
19     Faixa Etária_Faixa_4_Idade  13.673172  2.175401e-04
17     Faixa Etária_Faixa_2_Idade  6.777248  9.232713e-03
18     Faixa Etária_Faixa_3_Idade  5.116867  2.369436e-02
15     Região onde mora_Sul  4.504934  3.379720e-02
13     Região onde mora_Norte  3.411800  6.473179e-02
10     Cor/raca/etnia_Preta  2.481398  1.151998e-01
7      Cor/raca/etnia_Outra  2.434390  1.187001e-01
14     Região onde mora_Sudeste  2.413239  1.203132e-01
2      Área de formação em tecnologia  1.388476  2.386626e-01
5      Cor/raca/etnia_Branca  1.175545  2.782647e-01
16     Faixa Etária_Faixa_1_Idade  1.058870  3.034731e-01
8      Cor/raca/etnia_Parda  0.508096  4.759641e-01
9      Cor/raca/etnia_Prefiro não informar  0.404420  5.248153e-01
1      PCD  0.352259  5.528369e-01
11     Região onde mora_Centro-oeste  0.204575  6.510531e-01
4      Cor/raca/etnia_Amarela  0.082735  7.736241e-01
6      Cor/raca/etnia_Indígena  0.002508  9.600621e-01
```


Colunas removidas: ['Cor/raca/etnia_Indígena', 'Cor/raca/etnia_Amarela', 'PCD', 'Cor/raca/etnia_Prefiro não informar']
Formato do DataFrame após remoção: (5008, 17)

Conversão de dados

1. Discretização (Binning)

Esta transformação foi aplicada para converter a variável numérica contínua Idade em uma variável categórica ordinal.

Coluna Alvo	Transformação	Lógica	Novas Categorias (Rótulos)	Resultado
Idade	Agrupamento por Quartis (pd.cut)	A coluna foi dividida em 4 grupos de tamanho aproximadamente igual.	Faixa_1_Idade; Faixa_2_Idade; Faixa_3_Idade; Faixa_4_Idade;	Criação da coluna Faixa Etária e remoção da coluna Idade original.



2. Codificação por Rótulo (Label Encoding)


Aplicada para converter variáveis categóricas binárias ou ordinais em valores numéricos.

Coluna Alvo	Valor Original (Categoria)	Valor Novo (Numérico)
Nível de Ensino	Não tenho graduação formal	0
	Estudante de Graduação	1
	Graduação/Bacharelado	2
	Mestrado	3
	Doutorado ou Phd	4

Conversão de dados


3. One Hot Encoder

Cor/raca/etnia 5008 non-null object




Cor/raca/etnia_Amarela	5008	Categórico
Cor/raca/etnia_Branca	5008	Categórico
Cor/raca/etnia_Indígena	5008	Categórico
Cor/raca/etnia_Outra	5008	Categórico
Cor/raca/etnia_Parda	5008	Categórico
Cor/raca/etnia_Prefiro não informar	5008	Categórico
Cor/raca/etnia_Preta	5008	Categórico

Resultado dos atributos pré-processados



Atributo	Qtde de Instâncias	Tipo do atributo
Genero	5008	Categórico
PCD	5008	Categórico
Área de formação em tecnologia	5008	Categórico
Situação de trabalho	5008	Categórico
Nível de Ensino	5008	Categórico
Cor/raca/etnia_Amarela	5008	Categórico
Cor/raca/etnia_Branca	5008	Categórico
Cor/raca/etnia_Indígena	5008	Categórico
Cor/raca/etnia_Outra	5008	Categórico
Cor/raca/etnia_Parda	5008	Categórico
Cor/raca/etnia_Prefiro não informar	5008	Categórico
Cor/raca/etnia_Preta	5008	Categórico
Região onde mora_Centro-oeste	5008	Categórico
Região onde mora_Nordeste	5008	Categórico
Região onde mora_Norte	5008	Categórico
Região onde mora_Sudeste	5008	Categórico
Região onde mora_Sul	5008	Categórico
Faixa Etária_Faixa_1_Idade	5008	Categórico
Faixa Etária_Faixa_2_Idade	5008	Categórico
Faixa Etária_Faixa_3_Idade	5008	Categórico
Faixa Etária_Faixa_4_Idade	5008	Categórico



Indução de modelos

1º Modelo: Árvore de Decisão

Justificativas para escolha do modelo

- Interpretabilidade
- Tratamento de Dados Não-Lineares
- Requisitos Mínimos de Pré-processamento
- Base para Modelos Mais Complexos

Métodos para melhora do modelo

- Particionamento em Treino e Teste (75% treino e 25% teste)
- GridSearch (Cross-Validation) 5 folds
- Balanceamento de Classes com SMOTE dentro de um Pipeline

Parâmetros usados

- Profundidade máxima: 5,
- Mínimo de amostras por folha 2,
- Mínimo de amostras para dividir: 2





Resultados

Classe	Precision	Recall	F1-Score	Support
Empregado(a)	0.95	0.28	0.43	1144
Desempregado(a)	0.10	0.85	0.18	108
Weighted Avg	0.88	0.33	0.41	1252


Análise de Overfitting
Acurácia de Treino: 0.65
Acurácia de Teste: 0.33
Queda de Desempenho: -32 pontos percentuais

O overfitting está presente de forma significativa.


GRÁFICOS DO MODELO 01



Treino:




Teste:




Plotagem da árvore:

Árvore de Decisão Treinada



Feature Importance:



2º Modelo: Random Forest

Justificativas para escolha do modelo

- Redução de Overfitting e Maior Robustez
- Alto Desempenho Geral
- Importância de Features Confiável
- Tratamento de Dados Não-Lineares

Métodos para melhora do modelo

- Particionamento em Treino e Teste (75% treino e 25% teste)
- GridSearch (Cross-Validation) 5 folds
- Balanceamento de Classes com SMOTE dentro de um Pipeline

Parâmetros usados

- Profundidade máxima: 10,
- Mínimo de amostras por folha 2,
- Mínimo de amostras para dividir: 5,
- Numero de árvores geradas: 100



Resultados

Classe	Precision	Recall	F1-Score	Support
Empregado(a)	0.95	0.49	0.64	1144
Desempregado(a)	0.11	0.70	0.20	108
Weighted Avg	0.87	0.50	0.60	1252


Análise de Overfitting
Acurácia de Treino: 0.78
Acurácia de Teste: 0.50
Queda de Desempenho: -28 pontos percentuais

O overfitting também está presente de forma significativa, embora ligeiramente menor que na Árvore de Decisão.


GRÁFICOS DO MODELO 02




Treino:



Teste:



Feature Importance:



Análise Comparativa Direta

Métrica (Classe Desempregado(a))	Modelo 1 (Árvore de Decisão)	Modelo 2 (Random Forest)	Vencedor (para o objetivo)
Recall (Sensibilidade)	0.85	0.70	Árvore de Decisão
Precisão	0.10	0.11	Empate (ambos ruins)
F1-Score	0.18	0.20	Random Forest
Acurácia Geral	0.33	0.50	Random Forest
Overfitting (Queda)	-32 pts	-28 pts	Random Forest



Conclusão

O presente trabalho teve como objetivo o desenvolvimento de um modelo para identificar indivíduos em situação de desemprego.

A avaliação dos modelos foi centrada no objetivo de maximizar o recall, refletindo a importância social de identificar o maior número possível de desempregados.

FIM